Федеральное агентство связи
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Сибирский государственный университет телекоммуникаций и
информатики»
(СибГУТИ)

Кафедра ПМиК

Расчетно-графическое задание
по дисциплине
«Технология программирования графических ускорителей»

Выполнил:

студент гр. МГ-211 _____ / Бурдуковский И.А./

подпись

Проверил:

Профессор

кафедры ПМиК _____ / Малков Е. А./

ОЦЕНКА, подпись

Новосибирск 2023

Оглавление

Задание

Сравнительный анализ производительности программ, реализующих алгоритмы линейной алгебры с использованием библиотек Thrust, cuBLAS и «сырого» CUDA C кода.

За основу алгоритма линейной алгебры был взят алгоритм SAXPY

Теоретическая часть

Технология CUDA

Это программно-аппаратная вычислительная архитектура Nvidia, основанная на расширении языка Си, которая даёт возможность организации доступа к набору инструкций графического ускорителя и управления его памятью при организации параллельных вычислений. CUDA помогает реализовывать алгоритмы, выполнимые на графических процессорах видеоускорителей Geforce восьмого поколения и старше (серии Geforce 8, Geforce 9, Geforce 200), а также Quadro и Tesla.

CUDA использует параллельную модель вычислений, когда каждый из SIMD процессоров выполняет ту же инструкцию над разными элементами данных параллельно. GPU является вычислительным устройством, сопроцессором (device) для центрального процессора (host), обладающим собственной памятью и обрабатывающим параллельно большое количество потоков. Ядром (kernel) называется функция для GPU, исполняемая потоками (аналогия из 3D графики — шейдер).

Модель программирования в CUDA предполагает группирование потоков. Потоки объединяются в блоки потоков (thread block) — одномерные или двумерные сетки потоков, взаимодействующих между собой при помощи разделяемой памяти и точек синхронизации. Программа (ядро, kernel) исполняется над сеткой (grid) блоков потоков (thread blocks). Одновременно исполняется одна сетка. Каждый блок может быть одно-, двух- или трехмерным по форме, и может состоять из 512 потоков на текущем аппаратном обеспечении.

Блоки потоков выполняются в виде небольших групп, называемых варп (warp), размер которых — 32 потока. Это минимальный объём данных, которые могут обрабатываться в мультипроцессорах. И так как это не всегда удобно, CUDA позволяет работать и с блоками, содержащими от 64 до 512 потоков.

Группировка блоков в сетки позволяет уйти от ограничений и применить ядро к большему числу потоков за один вызов. Это помогает и при масштабировании. Если у GPU недостаточно ресурсов, он будет выполнять блоки последовательно. В обратном случае, блоки могут выполняться параллельно, что важно для оптимального распределения работы на видеочипах разного уровня, начиная от мобильных и интегрированных.

Модель памяти в CUDA отличается возможностью побайтной адресации, поддержкой как gather, так и scatter. Доступно довольно большое количество регистров на каждый потоковый процессор, до 1024 штук. Доступ к ним очень быстрый, хранить в них можно 32-битные целые или числа с плавающей точкой.

CUDA имеет несколько типов памяти. Эта технология предполагает специальный подход к разработке, не совсем такой, как принят в программах для CPU. Нужно помнить о разных типах памяти, о том, что локальная и глобальная память не кэшируется и задержки при доступе к ней гораздо выше, чем у регистровой памяти, так как она физически находится в отдельных микросхемах.

Thrust

Thrust - это библиотека параллельных алгоритмов, напоминающая библиотеку стандартных шаблонов (STL). Интерфейс высокого уровня Thrust значительно повышает производительность программистов, обеспечивая при этом переносимость производительности между графическими процессорами и многоядерными процессорами. Совместимость с установленными технологиями (такими как CUDA, TBB и OpenMP) облегчает интеграцию с существующим программным обеспечением.

cuBLAS

Библиотека cuBLAS обеспечивает реализацию с ускорением на GPU основных подпрограмм линейной алгебры (BLAS). cuBLAS ускоряет приложения AI и HPC с помощью стандартных отраслевых API-интерфейсов BLAS, оптимизированных для графических процессоров NVIDIA. Библиотека cuBLAS содержит расширения для пакетных операций, выполнения на нескольких графических процессорах, а также выполнения смешанной и низкой точности. Используя cuBLAS, приложения автоматически получают выгоду от регулярных улучшений производительности и новых архитектур GPU. Библиотека cuBLAS включена как в NVIDIA HPC SDK, так и в CUDA Toolkit.

Результат работы программы

```
4
Trust time: 1.66125
Cuda time: 0.074912
Cublas time: 0.46192

8
Trust time: 0.052224
Cuda time: 0.001408
Cublas time: 0.03744

16
Trust time: 0.037984
Cuda time: 0.00144
Cublas time: 0.038624

32
Trust time: 0.028448
Cuda time: 0.001472
Cublas time: 0.037888

64
Trust time: 0.044288
Cuda time: 0.00144
Cublas time: 0.039328

128
Trust time: 0.038912
Cuda time: 0.00144
Cublas time: 0.037632

256
Trust time: 0.043008
Cuda time: 0.001664
Cublas time: 0.037664

512
Trust time: 0.024576
Cuda time: 0.001504
Cublas time: 0.037536

1024
Trust time: 0.0256
Cuda time: 0.038304
Cublas time: 0.019616
```

```
2048
Trust time: 0.063488
Cuda time: 0.045408
Cublas time: 0.04384

4096
Trust time: 0.041984
Cuda time: 0.299072
Cublas time: 0.02032

8192
Trust time: 0.051136
Cuda time: 0.038144
Cublas time: 0.037792

16384
Trust time: 0.044256
Cuda time: 0.03856
Cublas time: 0.100032

32768
Trust time: 0.10864
Cuda time: 0.247264
Cublas time: 0.11952

65536
Trust time: 0.10512
Cuda time: 0.098336
Cublas time: 0.135328

131072
Trust time: 0.12768
Cuda time: 0.046176
Cublas time: 0.040384

262144
Trust time: 0.132704
Cuda time: 0.125568
Cublas time: 0.333088

524288
Trust time: 0.1328
Cuda time: 0.0536
Cublas time: 0.214464

1048576
Trust time: 0.161696
Cuda time: 0.06288
Cublas time: 0.14608
```

```
2097152
Trust time: 0.254624
Cuda time: 0.088352
Cublas time: 0.199488

4194304
Trust time: 0.264544
Cuda time: 0.696768
Cublas time: 0.246144

8388608
Trust time: 0.425696
Cuda time: 0.336672
Cublas time: 0.432192

16777216
Trust time: 0.720864
Cuda time: 0.51088
Cublas time: 1.59222
```

Сравнение производительности алгоритмов

Были собраны данные по времени выполнения алгоритмов «Сырой» CUDA C, cuBLAS, Thrust. Ниже представлен график на основе полученных данных.

степень	размерность массива	thrust	cuda	cublas
2	4	1,661250	0,074912	0,461920
3	8	0,052224	0,001408	0,037440
4	16	0,037984	0,014400	0,038624
5	32	0,028448	0,001472	0,037888
6	64	0,044288	0,001440	0,039328
7	128	0,038912	0,001440	0,037632
8	256	0,043008	0,001664	0,037664
9	512	0,024576	0,001504	0,037536
10	1024	0,025600	0,038304	0,019616
11	2048	0,063488	0,045408	0,043840
12	4096	0,041984	0,299072	0,020320
13	8192	0,051136	0,038144	0,037792
14	16384	0,044256	0,038560	0,100032
15	32768	0,108640	0,247264	0,119520
16	65536	0,105120	0,098336	0,135328
17	131072	0,127680	0,041760	0,040384
18	262144	0,132704	0,125568	0,333088
19	524288	0,132800	0,053600	0,214464
20	1048576	0,161696	0,062880	0,146080
21	2097152	0,254624	0,088352	0,199488
22	4194304	0,264544	0,696768	0,246144
23	8388608	0,425696	0,336672	0,432192

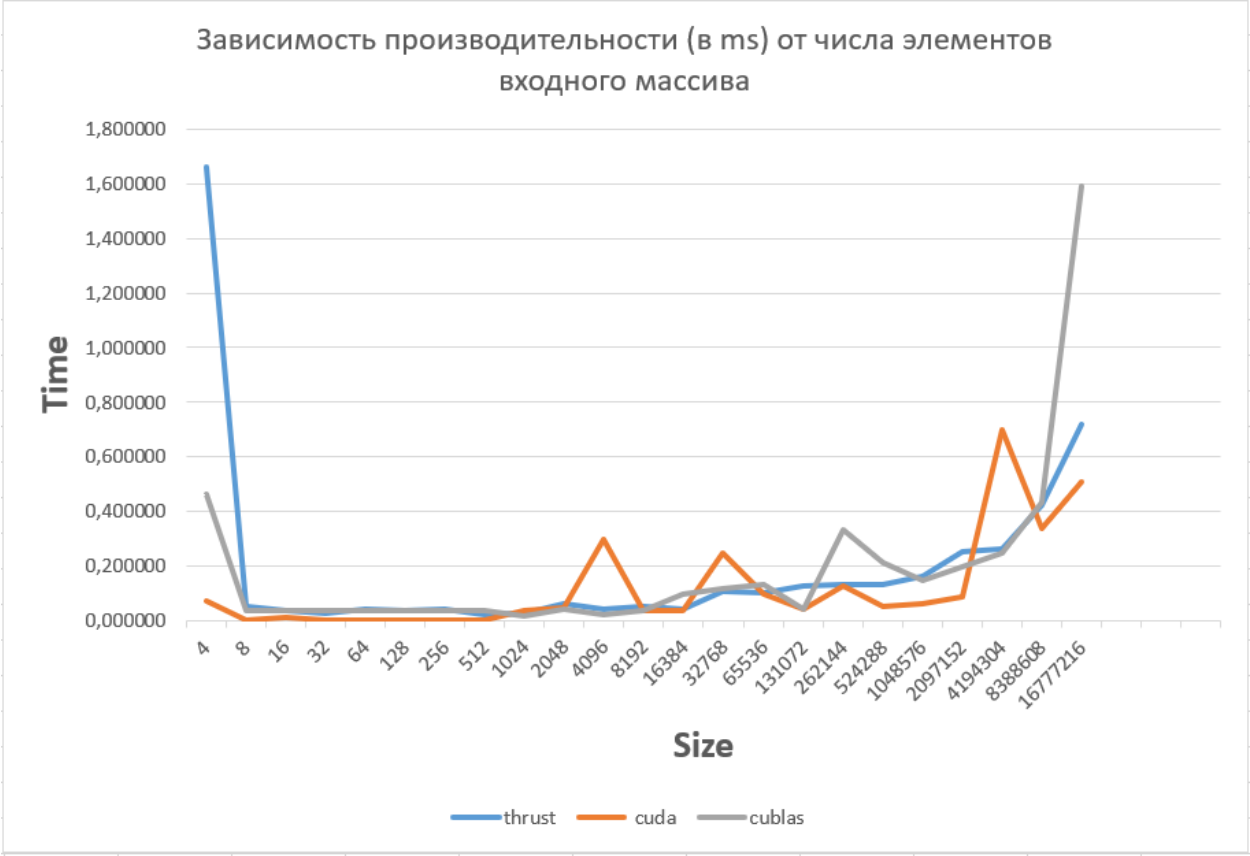

На графике видно, что по средней скорости выполнения лидирует «сырой» CUDA, но Thrust показал более стабильную скорость работы при увеличении объёма обрабатываемых данных, не смотря на общую медлительность алгоритма по сравнению с остальными.

Листинг

```
#include <thrust/host_vector.h>
#include <thrust/device_vector.h>
#include <thrust/transform.h>
#include <thrust/fill.h>
#include <thrust/sequence.h>
#include <cublas_v2.h>
#pragma comment (lib, "cublas.lib")
#include <cublas_v2.h>
#pragma comment (lib, "cufft.lib")
#include <cufft.h>
#include <cstdlib>
using namespace std;

struct saxpy_functor
{
	const float a;
	saxpy_functor(float _a) : a(_a) {}
	__host__ __device__ float operator()(float x, float y) {
		return a * x + y;
	}
};

void saxpy(float a, thrust::device_vector<float>& x, thrust::device_vector<float>& y){
	saxpy_functor func(a);
	thrust::transform(x.begin(), x.end(), y.begin(), y.begin(), func);
}

__global__ void cuda_saxpy(float *a, float *b, float alpha){
	int j = threadIdx.x + blockIdx.x * blockDim.x;
	a[j] = j;
	b[j] = 0.87;
	a[j] = alpha * a[j] + b[j];
}
```

```
__host__ void print_array(float *data1, float *data2, int num_elem, const char *prefix) {
	printf("\n%s", prefix);
	for (int i = 0; i < num_elem; i++)
		printf("\n%2d: %2.4f %2.4f", i + 1, data1[i], data2[i]);
}

void CudaTest(int shift){

	printf("%d\n", 1 << shift);
	float elapsedTime;
	cudaEvent_t start, stop;

	cudaEventCreate(&start);
	cudaEventCreate(&stop);

	// Trust
	thrust::host_vector<float> h1(1 << shift);
	thrust::host_vector<float> h2(1 << shift);
	thrust::sequence(h1.begin(), h1.end());
	thrust::fill(h2.begin(), h2.end(), 0.87);
	thrust::device_vector<float> d1 = h1;
	thrust::device_vector<float> d2 = h2;
	cudaEventRecord(start, 0);
	saxpy(3.0, d1, d2);
	cudaEventRecord(stop, 0);
	cudaEventSynchronize(stop);
	cudaEventElapsedTime(&elapsedTime, start, stop);
	printf("Trust time: %g\n", elapsedTime);
	h2 = d2;
	h1 = d1;

	// Raw Cuda
	float *h, *da, *db, alpha = 3.0F;
	int threads_per_block = 525, N = 1 << shift;
	int num_of_blocks = N / threads_per_block;
```

```
h = (float*)calloc(N, sizeof(float));
cudaMalloc((void**)&da, N * sizeof(float));
cudaMalloc((void**)&db, N * sizeof(float));
cudaEventRecord(start, 0);
cuda_saxpy << <dim3(num_of_blocks), dim3(threads_per_block) >> > (da, db, alpha);
cudaEventRecord(stop, 0);
cudaEventSynchronize(stop);
cudaEventElapsedTime(&elapsedTime, start, stop);
printf("Cuda time: %g\n", elapsedTime);
cudaMemcpy(h, da, N * sizeof(float), cudaMemcpyDeviceToHost);

// Cublas
const int num_elem = 1 << shift;
const size_t size_in_bytes = (num_elem * sizeof(float));
float *ha, *hb;
cudaMalloc((void**)&da, size_in_bytes);
cudaMalloc((void**)&db, size_in_bytes);
cudaMallocHost((void**)&ha, size_in_bytes);
cudaMallocHost((void**)&hb, size_in_bytes);
memset(ha, 0, size_in_bytes);
memset(hb, 0, size_in_bytes);
cublasHandle_t cublas_handle;
cublasCreate(&cublas_handle);
for (int i = 0; i < num_elem; i++) {
        ha[i] = (float)i;
        hb[i] = 0.87;
}
const int num_rows = num_elem;
const int num_cols = 1;
const size_t elem_size = sizeof(float);
cublasSetMatrix(num_rows, num_cols, elem_size, ha, num_rows, da, num_rows);
cublasSetMatrix(num_rows, num_cols, elem_size, hb, num_rows, db, num_rows);
const int stride = 1;
alpha = 3.0F;
cudaEventRecord(start, 0);
cublasSaxpy(cublas_handle, num_elem, &alpha, da, stride, db, stride);
```

```
        cudaEventRecord(stop, 0);
        cudaEventSynchronize(stop);
        cublasGetMatrix(num_rows, num_cols, elem_size, da, num_rows, ha, num_rows);
        cublasGetMatrix(num_rows, num_cols, elem_size, db, num_rows, hb, num_rows);
        const int default_stream = 0;
        cudaStreamSynchronize(default_stream);
        cudaEventElapsedTime(&elapsedTime, start, stop);
        printf("Cublas time: %g\n", elapsedTime);
        printf("\n");
        cublasDestroy(cublas_handle);
        cudaEventDestroy(start);
        cudaEventDestroy(stop);
        cudaFreeHost(ha);
        cudaFreeHost(hb);
        cudaFree(da);
        cudaFree(db);
        free(h);
}

int main() {
        int shift = 2;
        for(;shift <= 24; shift++){
                CudaTest(shift);
        }
        system("pause");
        return 0;
}
```